

中文引用格式：周新民，余焕杰.基于动态图卷积与时空注意力的城市交通流量预测模型[J].中国安全科学学报，2026，3? ( ? ) : ? - ? .

英文引用格式：ZHOU Xinmin, YU Huanjie. A traffic flow forecasting model for urban areas based on dynamic graph convolution and spatio-temporal attention[J].China Safety Science Journal,2026, 3? ( ? ) : ? - ? .

# 基于动态图卷积与时空注意力的 城市交通流量预测模型

周新民<sup>1,2</sup> 教授， 余焕杰<sup>3</sup>

(1 湖南工商大学 人工智能与先进计算学院, 湖南 长沙 410205; 2 湘江实验室, 湖南 长沙 410205;

3 湖南工商大学 计算机学院, 湖南 长沙 410205 )

文章编号：1003-3033 (202? ) 00-0000-00; 收稿日期：202? -00-00; 修稿日期：202? -00-00

中图分类号：X951 文献标志码：A DOI: 10.16265/j.cnki.issn 1003-3033.2026.00.000

基金项目：国家社会科学基金资助 (21BGL231) ; 湘江实验室重大项目 (23XJ01001) 。

\*通信作者简介：周新民 (1977—)，男，湖南新邵人，博士，教授，博士生导师，主要从事新型智慧城市、商务智能与大数据、人工智能大模型等方面的研究。E-mail: zhouxinmin2699@163.com。

**【摘要】**为解决城市交通流量预测中时空耦合特征挖掘不充分、模型泛化能力不足的问题，提出一种动态图卷积与时空注意力融合的 STMAT 模型。该模型通过融合近期、周期、趋势多尺度时间特征与路网空间拓扑信息，构建双分支时空编码模块；设计动态图卷积增强模块，基于切比雪夫多项式近似降低计算复杂度，实现时空特征耦合提取；引入分层时空注意力模块，分时段捕捉空间异质性与时间周期性依赖；通过时空融合块融合静态路网与动态交通关联，并优化输入维度与超参数自适应机制。基于 SZ\_TAXI 与 PEMS3 数据集共 5 个数据集，与 13 个主流基线模型对比验证。结果表明，模型在 4 个数据集上的平均绝对误差 (MAE) 和平均绝对百分比误差 (MAPE) 均为最优，仅在 PEMS3 数据集 MAPE 略逊于 DSTAGNN 但 MAE 保持最优；消融实验证实各核心模块均能提升预测性能，可视化分析中预测值与真实流量拟合度高，证实模型可稳定捕捉日常波动与突发变化，有效提升复杂场景下交通流量预测的精度与适配性。

**【关键词】** 动态图卷积；时空注意力；交通流量预测；时空特征提取；自适应优化

## A traffic flow forecasting model for urban areas based on dynamic graph convolution and spatio-temporal attention

ZHOU Xinmin<sup>1,2</sup>, YU Huanjie<sup>3</sup>

(1 School of Artificial Intelligence and Advanced Computing, Hunan University of Technology and Business, Changsha 410205, Hunan, China; 2 Xiangjiang Lab, Changsha 410205, Hunan, China; 3 School of Computer Science, Hunan University of Technology and Business, Changsha 410205, Hunan, China)

**Abstract:** To address the problems of insufficient mining of spatio-temporal coupling characteristics and poor model generalization ability in urban traffic flow prediction, a spatio-temporal Multi-scale Attention model integrated with Dynamic Graph Convolution (STMAT) is proposed. This model constructs a dual-branch spatio-temporal encoding module by fusing multi-scale temporal features (including short-term, periodic, and trend components) with the spatial topology information of road networks, thereby capturing the multi-dimensional temporal patterns and inherent spatial correlations of traffic flow simultaneously. A dynamic graph convolution enhancement module is designed to reduce computational complexity based on Chebyshev polynomial approximation, which enables efficient and effective coupled extraction of spatio-temporal features by adaptively adjusting the graph structure according to real-time traffic changes. Additionally, a hierarchical spatio-temporal attention module is introduced to capture spatial heterogeneity

and temporal periodic dependencies in different time periods, enhancing the model's ability to focus on key spatio-temporal regions and periodic patterns. A spatio-temporal fusion block is adopted to integrate static road network attributes and dynamic traffic correlations, and the input dimension and hyperparameter adaptive mechanism are optimized to improve the model's adaptability to different traffic scenarios. Validation experiments are conducted on 5 datasets from the SZ\_TAXI and PEMS3D series, with comparisons against 13 state-of-the-art baseline models. The experimental results indicate that the STMAT model achieves the optimal Mean Absolute Error (MAE) and Mean Absolute Percentage Error (MAPE) on 4 out of the 5 datasets. Only on the PEMS3D dataset, its MAPE is slightly inferior to that of DSTAGNN, while the MAE still maintains the best performance. Ablation experiments confirm that each core module of the STMAT contributes significantly to improving the prediction performance. In visual analytics, the predicted values show a high fitting degree with the actual traffic flow, verifying that the model can stably capture daily traffic fluctuations and sudden changes. Overall, the proposed STMAT effectively enhances the accuracy and adaptability of traffic flow prediction in complex urban scenarios.

**Keywords:** dynamic graph convolution; spatio-temporal attention; traffic flow forecasting; spatio-temporal feature extraction; adaptive optimization

## 0 引言

随着城市化进程加速与城市人口持续增长，道路交通承载压力日益凸显，不仅易引发大范围交通拥堵，更增加了交通事故的发生风险，严重影响城市运行效率与居民出行安全<sup>[1]</sup>。交通流量作为城市交通系统的核心表征，其精准预测是优化出行路线规划、缓解高峰拥堵、提升交通管理智能化水平的关键前提。城市交通流量具有显著的时空耦合特性、多尺度关联特征与动态演化规律，同时受天气、节假日、路网拓扑等多重因素影响，如何从海量时空数据中挖掘复杂特征并实现高精度预测，已成为智能交通领域亟待解决的核心问题。

目前，交通流量预测方法主要分为统计理论模型与深度学习模型两大类。传统统计模型如自回归积分移动平均模型（Autoregressive Integrated Moving Average Model, ARIMA）、向量自回归模型（Vector Autoregressive Model, VAR）<sup>[2]</sup>等，虽能捕捉交通流量的中长期变化趋势，但对流量的随机性波动与时空动态关联性敏感不足，难以适配复杂交通场景<sup>[1]</sup>。随着深度学习技术的发展，卷积神经网络（Convolutional Neural Network, CNN）<sup>[3]</sup>、长短时记忆网络（Long Short-Term Memory, LSTM）<sup>[4]</sup>等模型被广泛应用于交通预测，其中 CNN 擅长提取空间局部特征，LSTM 能够捕捉时序依赖关系。然而，单一模型难以同时充分挖掘交通流量的时空耦合特性，例如 CNN 难以处理长序列时间依赖，LSTM 对空间关联的捕捉能力有限。

近年来，学者们通过模型融合与结构改进提升预测性能，Zhang 等<sup>[5]</sup>提出深度时空残差网络（Deep Spatio-Temporal Residual Network, ST-ResNet）通过残差结构加深网络以强化空间特征提取；Zhang 等<sup>[6]</sup>提出的图卷积网络（Graph Convolutional

Network, GCN）及 Li 等<sup>[7]</sup>提出的动态图卷积循环网络（Dynamic Graph Convolutional Recurrent Network, DCRNN）通过引入路网拓扑信息来捕捉空间关联；部分模型如周新民等<sup>[8]</sup>提出的注意力卷积长短时记忆残差（Attentive Convolutional LSTM Residual Network, ACLR）模型，通过引入注意力机制、残差结构或图增强模块，进一步优化时空特征提取能力。此外，针对时空依赖建模的精细化需求，Song 等<sup>[9]</sup>提出的注意力时空图卷积网络（Attention Spatio-Temporal Graph Convolutional Network, ASTGCN），通过设计空间注意力与时间注意力双模块，精准聚焦关键时空区域以强化有效特征的捕捉。

但现有研究仍存在不足，部分模型忽略交通流量的多尺度时间异质性与空间异质性，静态图卷积难以适配路网动态关联变化，且部分模型存在输入维度固定、超参数适配性差等问题，导致泛化能力受限，难以兼容不同城市规模、时间粒度的交通数据集。

鉴于此，针对现有模型的局限性，本文充分挖掘交通流量的时空耦合特性、多尺度关联特征与动态演化规律，提出时空多尺度注意力图模型（Spatio-Temporal Multi-Scale Attention Graph Model, STMAT）。该模型通过融合多尺度时间特征与路网空间拓扑信息，构建双分支时空编码模块，集成动态图卷积与分层时空注意力机制，同时设计时空融合块实现静态路网与动态交通关联的深度融合，并通过输入维度与超参数自适应优化提升模型泛化能力。基于多个不同城市、时间粒度的数据集开展试验验证，以期提升复杂场景下交通流量预测的精度与适配性，为城市智能交通系统优化提供技术支撑。

## 1 基于 STMAT 模型的城市交通流量预测

充分挖掘城市道路交通流量的时空耦合特性、多尺度关联特性与动态演化规律，是提升复杂场景下流量预测精度与泛化能力的核心前提。STMAT 模型主要通过以下 3 个维度强化特征表达与预测性能：①针对交通流量在时间维度上的多尺度异质性，融合近期、周期、趋势三类时间特征，构建以多时间步长为索引的输入数据集；同时引入邻接矩阵的拉普拉斯标准化，精准捕获路网空间拓扑关联，实现时空特征的初步解构与对齐。②基于模块

化设计思想，构建双分支时空编码模块，在模块内部集成动态邻接矩阵生成机制与时空注意力机制：通过长短期记忆 LSTM 层捕捉时序依赖，结合空间注意力与时间注意力动态加权特征权重，引入切比雪夫图卷积挖掘复杂空间关联，并以残差连接与层归一化缓解梯度消失，增强特征的深度提取与传递能力。③设计多尺度特征融合与输出解码单元，对不同时间尺度卷积层的输出进行自适应加权融合，同时耦合多时间尺度特征的全局关联，最终生成兼具局部精准性与全局一致性的交通流量预测结果。STMAT 预测模型框架如图 1 所示。

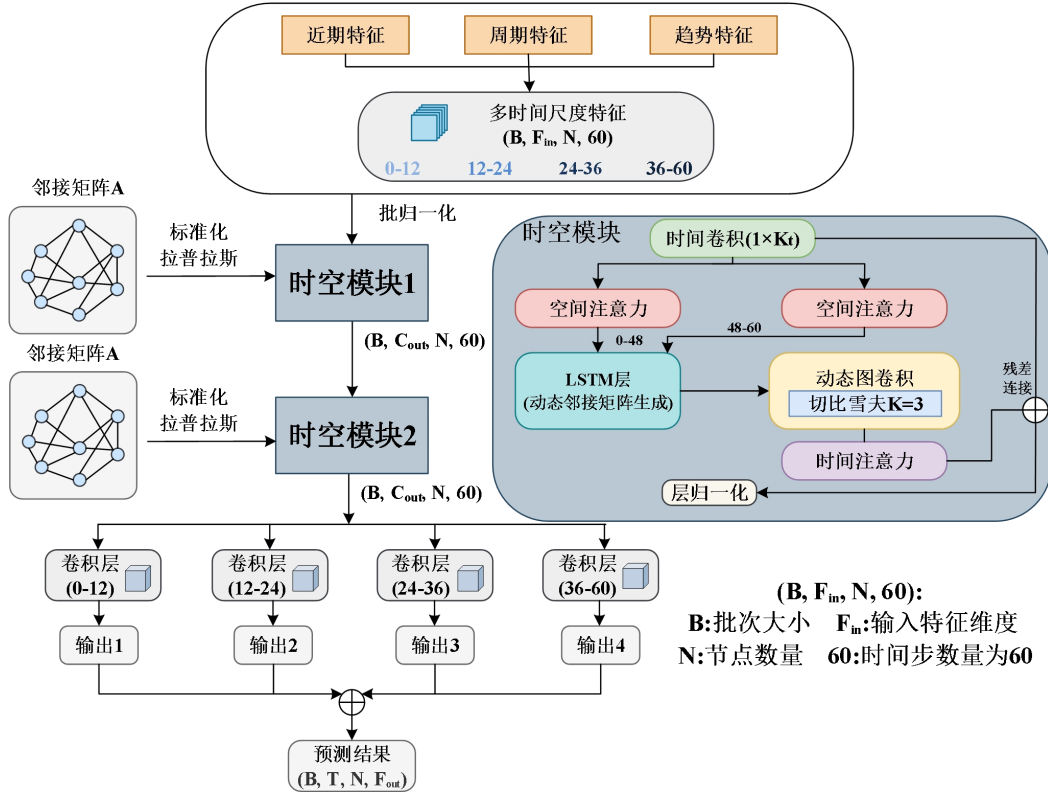


图 1 STMAT 预测模型框架

Fig.1 Framework of STMAT prediction model

### 1.1 动态图卷积增强模块

针对大规模路网下静态图卷积计算复杂度高、无法适配动态时空关联的问题，本研究设计动态图卷积增强模块，核心思路是通过切比雪夫多项式近似图卷积，在降低计算复杂度的同时实现时空特征的耦合提取。

传统图卷积直接基于拉普拉斯矩阵  $L$  计算，复杂度为  $O(N^2)$ （ $N$  为路网节点数），当  $N$  达到 800 以上时计算效率显著下降。为解决这一问题，模块采用  $K$  阶切比雪夫多项式对标准化拉普拉斯矩阵  $\tilde{L}$  进行近似，其递推关系为：

$$\begin{aligned} T_0(\tilde{L}) &= I, \\ T_1(\tilde{L}) &= \tilde{L}, \\ T_k(\tilde{L}) &= 2\tilde{L}T_{k-1}(\tilde{L}) - T_{k-2}(\tilde{L}) \end{aligned} \quad (1)$$

其中  $I$  为单位矩阵， $k = 2, 3, \dots, K-1$ 。

经近似后，图卷积的计算复杂度降至  $O(KN)$ ，本研究取  $K = 3$ ，在保证空间关联捕捉能力的同时，将计算量降低约两个数量级。

在此基础上，模块进一步将空间图卷积与时间卷积协同设计：首先通过爱因斯坦求和将输入特征与切比雪夫多项式序列融合，得到多阶空间特征  $X_{spatial}$ ；随后应用  $1 \times K_t$  ( $K_t = 3$ ) 的时间卷积核，对空间特征进行局部时间卷积，提取时间维度的局部依赖，最终输出时空耦合特征，如图 2 所示。

这一设计可适配 300s/900s 不同时间粒度的交通数据，例如在 SZ\_TAXI 数据集（900s 粒度）中，时间卷积核可有效捕捉 3 个连续时间步的流量变化关联，而在 PEMS3 系列数据集（300s 粒度）中则适配更精细的时间依赖，因此此设计加强了模型对多种数据集的适配性。

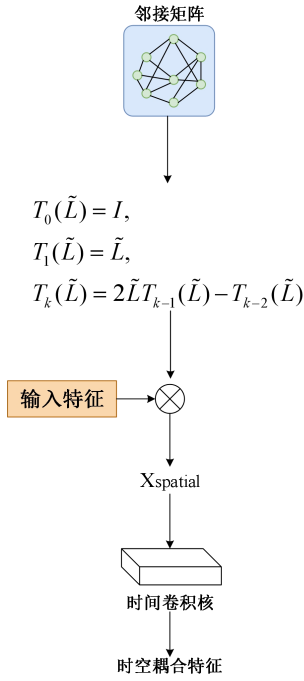


图 2 动态图卷积的时空耦合结构

Fig.2 Spatio-temporal coupling structure of dynamic graph convolution

### 1.2 分层时空注意力模块

交通流的时空特征具有显著的时段异质性，具体表现为在平峰时段空间关联较弱且变化平缓，而在高峰时段空间关联强且波动剧烈；同时时间维度存在邻近性与周期性的双重依赖。针对这一特性，分层时空注意力模块采用双分支结构实现精准特征提取。

空间注意力子模块基于时段异质性设计分时段处理逻辑，将输入的 60 时间步特征划分为前 48 步（长时段，平峰/缓峰）与后 12 步（短时段，高峰），分别通过  $1 \times 1$  卷积降维得到特征分支  $F_1$  与  $F_2$ ，再经爱因斯坦求和计算节点间的动态关联权重：

$$S_{att} = \text{sigmoid}(F_1 \otimes F_2) \quad (2)$$

其中  $\otimes$  为爱因斯坦求和操作。为避免局部特征过载，权重经 *LayerNorm* 归一化后输出，如图 3 所示，确保不同时段的的空间关联特征得到均衡捕捉。

时间注意力子模块则针对时间周期性设计区间掩码机制，构建  $60 \times 60$  的掩码矩阵  $M$ ：

$$M_{i,j} = \begin{cases} 1, & \text{若时间步 } i, j \text{ 属于同周期} \\ -10^{13}, & \text{否则} \end{cases} \quad (3)$$

该掩码仅允许同周期时间步（如昨日 8 时与今日 8 时）交互，如图 4 所示，黑色区域则为允许交互区间，以此强化时间邻近性与周期性特征。在此基础上，通过双卷积分支提取时间-节点特征，结合可学习参数矩阵计算注意力得分，经 *Softmax* 与掩码约束生成时间注意力权重，最终对特征进行加权增强。

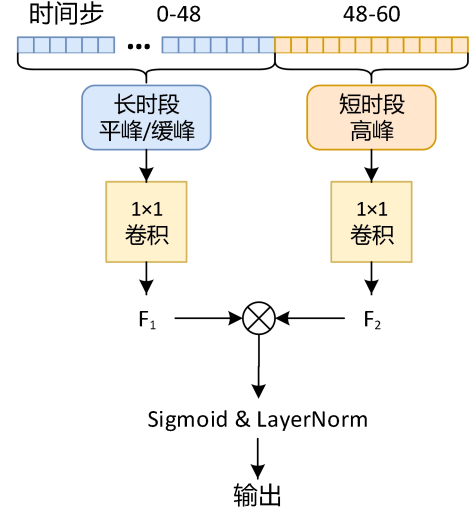


图 3 空间注意力分时段处理流程图

Fig.3 Spatial attention time-Slice processing flowchart




图 4 时间注意力区间掩码矩阵热力图

Fig.4 Time attention interval mask matrix heatmap

### 1.3 时空融合块

时空融合块是模型的核心计算单元，其设计目标是实现“静态路网拓扑+动态交通关联”的深度融合，并提升模型训练稳定性。

模块首先基于空间注意力权重生成动态邻接矩阵：以空间注意力权重为输入，通过 LSTM 学习路网关联的时序变化，得到动态邻接矩阵  $A_{dynamic}$ ，随后将其与静态拉普拉斯矩阵  $\tilde{L}$  加权融合：

$$A_{fusion} = A_{dynamic} \odot \tilde{L} \quad (4)$$

其中  $\odot$  为哈达玛积。这一融合策略既保留了路网的固有拓扑结构，又能适配不同时段的交通流动态变化，例如在早高峰时段，动态邻接矩阵会强化主要干道的节点关联，而静态拉普拉斯矩阵则维持路网的基础连接。

为缓解深层网络的梯度消失问题，模块引入门控与残差机制：将动态图卷积的输出拆分为特征过



滤分支 *Filter* 与门控分支 *Gate* ,通过 *sigmoid* 激活实现特征的选择性增强:

$$X_{filtered} = \text{sigmoid}(Gate) \cdot \text{LeakyReLU}(Filter) \quad (5)$$

随后通过残差连接将模块初始输入与过滤后的特征相加:

$$X_{residual} = X_{filtered} + X_{input} \quad (6)$$

最后经 *LayerNorm* 归一化处理, 具体如图 5 所示, 以达到适配多数据集的特征分布差异, 提升模型泛化能力的目的。

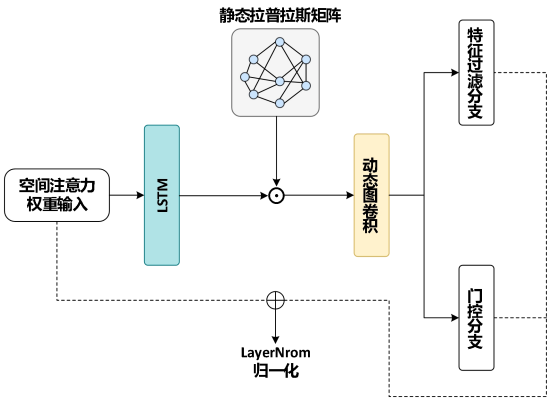


图 5 时空融合块的完整结构

Fig.5 Complete Structure of the Spacetime Fusion Block

### 1.4 模型适配与优化

为消除原始代码中硬编码对输入维度的限制, 本研究从输入维度与超参数两方面进行适配优化。

输入维度自适应方面, 模块不再依赖固定的 60 时间步硬编码, 而是基于 *config.json* 配置文件动态解析时间步长度与时段划分规则, 例如在 *SZ\_TAXI* 数据集(900s 粒度)中解析为 60 时间步, 在 *PEMSD3* 数据集(300s 粒度)中则根据配置调整为 48 时间步, 同时通过  $1 \times 1$  卷积动态调整输入特征维度, 兼容仅含流量特征或同时含流量、速度特征的数据集。

超参数自适应调整方面, 针对不同数据集的点位数与样本量, 动态优化图卷积阶数  $K$  与时间卷积核  $K_t$ : 例如在小规模数据集中取  $K=2$  以减少计算量, 在大规模数据集中取  $K=3$  以保证空间关联捕捉能力; 同时在注意力模块与图卷积模块中嵌入 *Dropout* 层, 抑制过拟合, 提升模型在跨场景下的泛化能力。这些优化使得模型可适配不同城市规模、路网密度的交通场景, 为多源数据集的统一预测提供了高效解决方案。

## 2 预测模型试验与分析

### 2.1 数据集信息及试验设置

试验所用的五个数据集如表 1 所示。所选用的数据集覆盖不同城市、时间粒度、区域规模与样本量, 确保实验的全面性。

表 1 试验数据集信息

Table 1 Information of experimental datasets

数据集	时间间隔/s	区域/点位数量	可训练样本量	时间范围
SZ_TAXI <sup>[1]</sup> <sub>0]</sub>	900	156	2964	2015-01-01—2015-01-31
PEMSD3	300	358	26196	2018-09-01—2018-11-30
PEMSD4	300	307	16980	2018-01-01—2018-02-28
PEMSD7	300	883	28212	2017-05-01—2020-08-31
PEMSD8	300	170	17844	2016-07-01—2016-08-31

### 2.2 数据预处理

试验所用数据集都处理成如表 2 所示的原子文件格式<sup>[11]</sup>。

表 2 数据集文件及内容

Table 2 Datasets files and contents

文件	内容	示例
.geo	存储地理实体属性信息	geo_id, type, coordinates
.rel	存储实体间的关系信息	rel_id, type, origin_id, destination_id
.dyna	存储交通状态信息	dyna_id, type, time, entity_id, location_id
.json	用于补充描述各表信息	{"geo": {"including_types": ["Point"], "Point": {}}}

在数据清洗方面, 对于超出合理流量范围的异常数据进行剔除, 并采用邻域插值法填补缺失值。

在数据结构化方面, 从 *dyna* 文件提取交通状态数据, 转化为“Batch×特征数×点位数量×时间步”的时空矩阵; 基于 *geo* 文件获取点位地理坐标, 构建初始路网邻接矩阵; 利用 *rel* 文件补充实体关联信息, 优化邻接矩阵权重;

在数据标准化方面, 采用 Min-Max 归一化处理流量数据, 通过 *BatchNorm2d* 层消除特征量纲差异。

在数据集划分方面, 统一按“训练集:验证集:测试集=7:1:2”划分, 确保对比实验的公平性。

### 2.3 评估指标定义

试验选取采用交通预测领域主流指标平均绝

对误差损失(Mean Absolute Error, MAE)和平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)作为模型评估指标,确保结果可比性,其定义如下:

$$MAE = \frac{1}{n} \sum_{i=1}^n |X_i - \hat{X}_i| \quad (7)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{X_i - \hat{X}_i}{X_i} \right| \quad (8)$$

其中,  $X_i$  为第  $i$  个样本的真实值,  $\hat{X}_i$  为第  $i$  个样本的预测值。

## 2.4 试验结果分析

为了全面评估本文模型的预测性能,我们将其与 13 个主流基线模型展开对比,其中既包含历史平均模型(History Average, HA)、ARIMA、VAR

等经典统计模型,也涵盖 FC-LSTM、DCRNN、GraphWaveNet 等深度学习基准模型,同时纳入了 ASTGCN、MSTGCN、STSGCN 等近年来表现突出的时空融合预测模型。

试验中,输入特征维度设置为 64,初始学习率设为 0.001, batch-size 为 32, epoch 设为 100。各数据集上不同模型的 MAE 和 MAPE 值如表 3 所示。

由表可知,HA、ARIMA、VAR 等经典统计模型在处理具有时空耦合特性的交通数据时,预测精度整体偏低,MAE 与 MAPE 指标均显著高于深度学习类模型。进一步对比各模型的性能可以发现,本文模型在绝大多数数据集上展现出最优的预测效果:在 SZ\_TAXI、PEMSD4、PEMSD7、PEMSD8 这 4 个数据集上,本文模型的 MAE 与 MAPE 指标均为所有模型中的最小值;仅在 PEMS3 数据集的 MAPE 指标上略逊于 DSTAGNN,但该数据集上的 MAE 指标仍保持最优。

表 3 各数据集上不同模型的 MAE 和 MAPE 值

Table 3 MAE and MAPE values of different models on various datasets

模型	SZ_TAXI		PEMSD3		PEMSD4		PEMSD7		PEMSD8	
	MAE	MAPE/%	MAE	MAPE/%	MAE	MAPE/%	MAE	MAPE/%	MAE	MAPE/%
HA	8.77	12.5	31.58	33.78	38.03	27.88	45.12	24.51	34.86	27.88
ARIMA	7.80	11.2	35.41	33.78	33.73	24.18	38.17	19.46	31.09	22.73
VAR	5.62	9.82	23.65	24.51	24.51	17.24	50.22	32.22	19.19	13.10
FC-LSTM	5.83	10.13	21.33	23.33	26.77	18.23	29.98	13.20	19.19	13.10
DCRNN	2.98	8.64	17.99	18.34	21.22	14.17	25.22	11.82	17.86	11.45
GraphWaveNet	3.02	8.95	19.12	18.89	24.89	17.29	26.39	11.97	18.28	12.15
ASTGCN	3.01	8.78	17.34	17.21	22.92	16.56	24.01	10.73	18.25	11.64
MSTGCN	2.91	8.43	19.54	23.86	23.96	14.33	29	14.30	19.00	12.38
STSGCN	2.96	8.26	17.48	16.78	21.19	13.90	24.26	10.21	17.13	10.96
STFGNN	2.92	7.94	16.77	16.30	20.48	16.77	23.46	9.21	16.94	10.60
STSGRU	2.91	7.64	15.45	15.85	20.11	13.86	21.5	9.08	15.68	10.67
AGCRN	3.06	7.43	15.98	15.23	19.83	12.97	22.37	9.12	15.95	10.09
DSTAGNN	<u>2.85</u>	<u>6.98</u>	<u>15.57</u>	<b>14.68</b>	<u>19.30</u>	<u>12.70</u>	<u>21.42</u>	<u>9.01</u>	<u>15.67</u>	<u>9.94</u>
本文模型	<b>2.68</b>	<b>6.44</b>	<b>15.23</b>	<u>14.83</u>	<b>18.65</b>	<b>12.39</b>	<b>20.56</b>	<b>8.42</b>	<b>14.71</b>	<b>9.45</b>

## 2.5 消融实验对比分析

为验证本文模型中各核心子模块对预测性能的贡献,设计 4 种变体消融模型,分别是①变体 1:移除动态图卷积增强模块,仅保留基础图卷积操作;②变体 2:移除分层空间注意力子模块,不再对空间关联特征进行差异化加权;③变体 3:移除分层时间注意力子模块,取消对时间序列依赖关系的建模;④变体 4:移除动态邻接矩阵生成模块,采用固定邻接矩阵进行图结构建模。

从图 6 左侧的消融实验结果可以看出,任意子模块的移除都会导致模型 MAE 与 MAPE 指标上升,预测性能出现不同程度的下降。其中,移除分层空间注意力子模块(变体 2)与动态邻接矩阵生成模块(变体 4)后,模型性能下滑最为显著,

说明对空间关联特征的动态捕捉是提升预测精度的核心环节;动态图卷积增强模块(变体 1)与分层时间注意力子模块(变体 3)的移除也会造成性能损失,验证了各子模块的协同作用能够有效提升模型对时空耦合特征的表达能力。

## 2.6 预测结果可视化分析

为进一步直观评估本文模型的预测效果,图 6 右侧在多个数据集上,随机抽取的节点样本在连续时间步内的真实流量值与预测值对比曲线。图中预测曲线与真实流量曲线拟合度较高,表明模型具备可靠的交通流预测能力,在不同规模的数据集上均展现出良好的泛化性能。但由于交通数据中存在随机噪声干扰,模型在局部流量突变的细节预测上仍存在一定误差,这也是后续研究中可优化的方向。

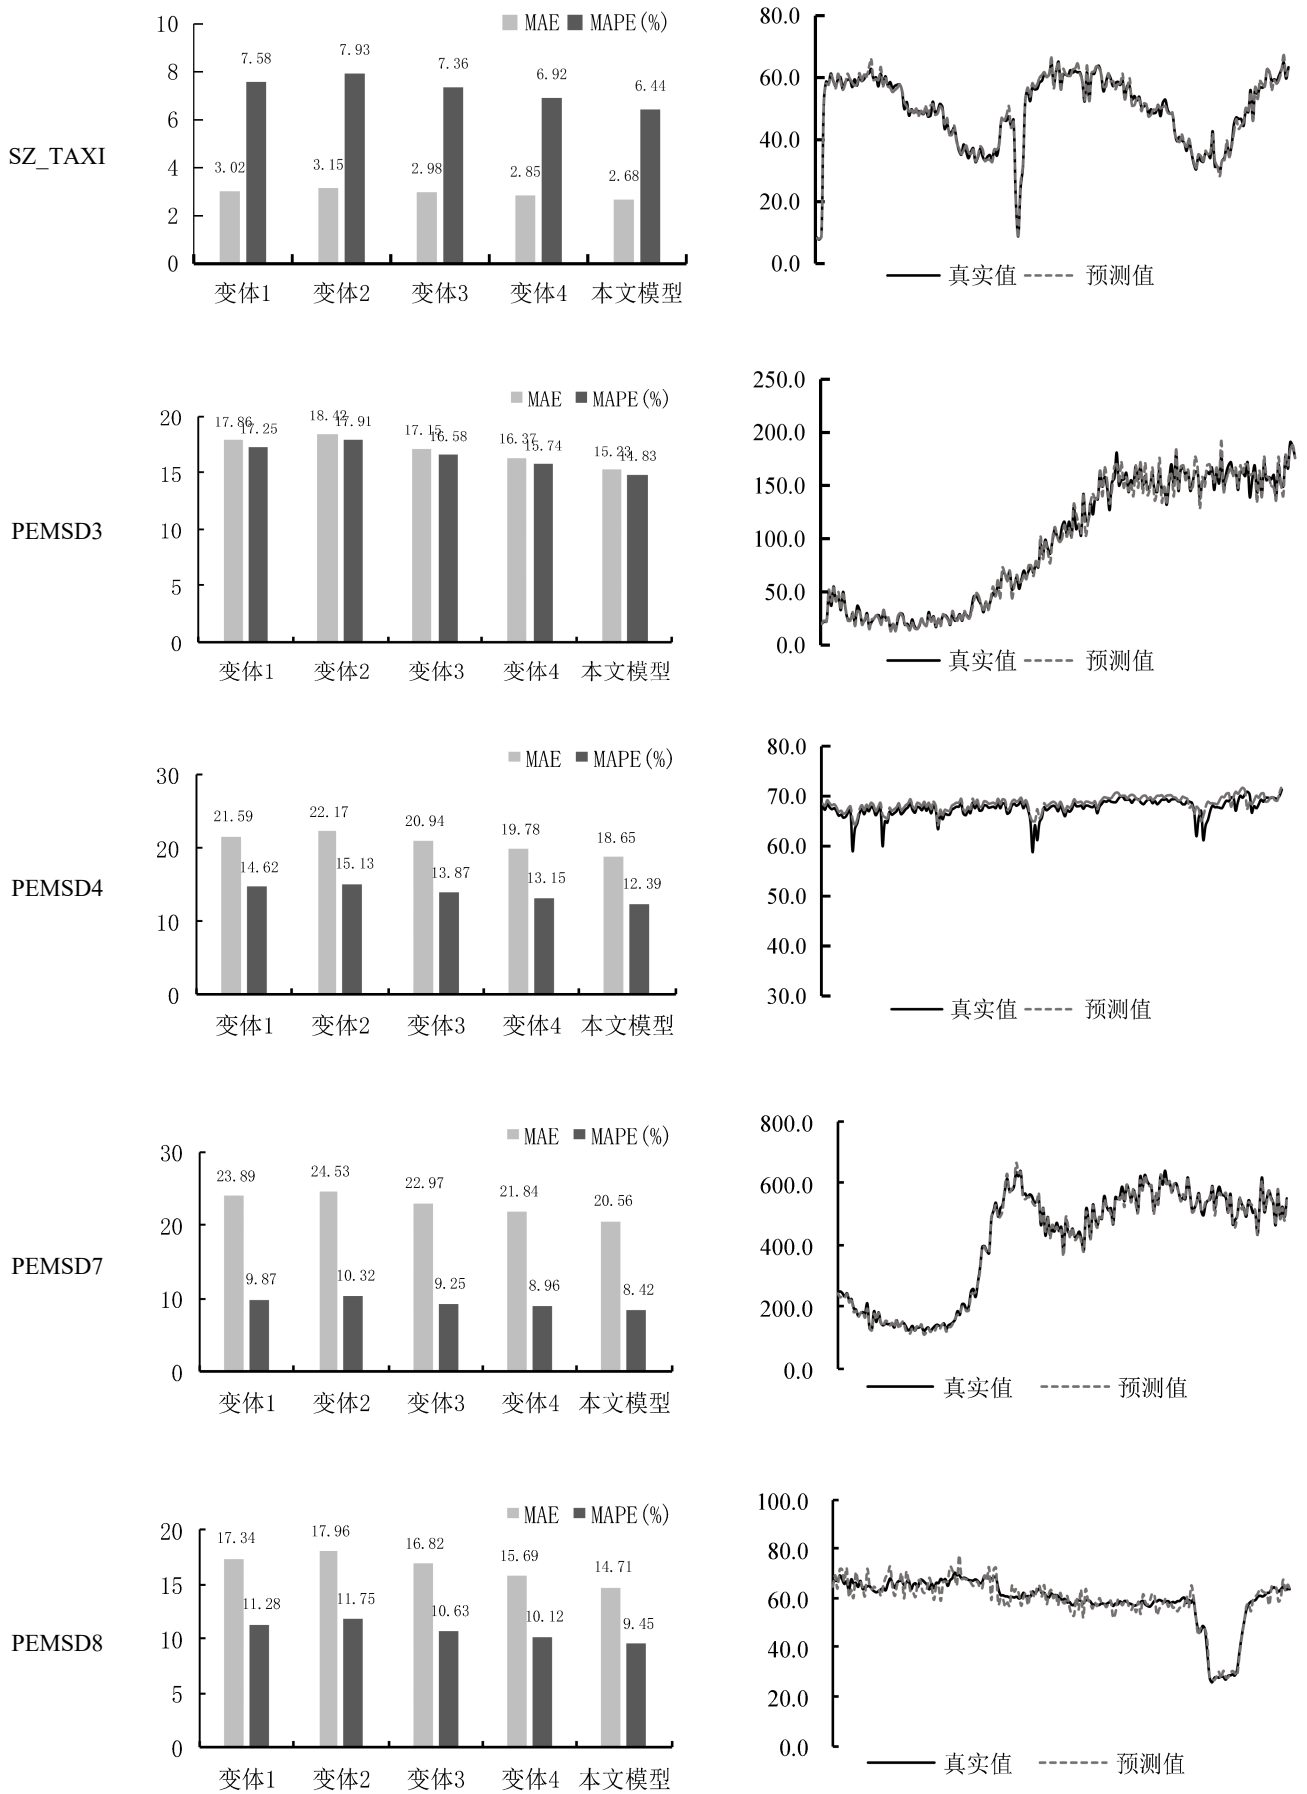


图 6 消融实验结果（左）与预测结果可视化（右）

Fig.6 Visualization of ablation experiment results (left) and predicted outcomes (right)

### 3 结论

1) 模型采用三维度特征强化策略:融合多类时间特征并结合拉普拉斯标准化实现时空特征对齐,双分支时空编码模块强化深层特征提取,多尺度特征融合单元生成兼具局部精准性与全局一致性的预测结果。

2) 核心子模块解决技术难题:动态图卷积增强模块降低计算复杂度并适配不同时间粒度数据,分层时空注意力模块精准捕捉时空异质性特征,时空融合块实现静态路网与动态交通关联的深度融合,输入与超参数自适应优化增强了模型泛化能力。

3) 试验验证了模型优越性:在 5 个数据集上,STMAT 模型的 MAE 与 MAPE 指标整体优于 13 个主流基线模型,4 个数据集取得最优性能;消融试验证实各核心模块均对预测性能有显著贡献,可视化结果表明模型能稳定捕捉日常流量波动与突发变化。

4) 模型存在一定局限性:受随机噪声影响,局部流量突变的细节预测仍有优化空间。未来将融合多源动态数据,优化噪声抑制与突变流量捕捉策略,探索与复杂路网信息的深度结合,进一步提升模型的实用价值。

### 参考文献

- [1] 周新民,徐天,李达,等.基于自适应时空多头图注意力网络的交通流量预测模型[J].中国安全科学学报,2025,35(11):149-156.  
ZHOU Xinmin, XU Tian, LI Da, et al. Traffic flow prediction model based on adaptive spatio-temporal multi-head graph attention network [J]. China Safety Science Journal, 2025, 35 (11):149-156.
- [2] CHANDRA S R, AL-DEEK H. Predictions of freeway traffic speeds and volumes using vector autoregressive models[J]. Journal of Intelligent Transportation Systems, 2009,13(2):53-72.
- [3] MA X, DAI Z, HE Z, et al. Learning traffic as images: A deep convolutional neural network for large-scale transportation network speed prediction[J]. sensors, 2017,17(4):818.
- [4] MA X, TAO Z, WANG Y, et al. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data[J]. Transportation Research Part C: Emerging Technologies, 2015,54:187-197.
- [5] ZHANG J, ZHENG Y, QI D. Deep spatio-temporal residual networks for citywide crowd flows prediction; proceedings of the Proceedings of the AAAI conference on artificial intelligence, F, 2017 [C].
- [6] ZHANG S, TONG H, XU J, et al. Graph convolutional networks: a comprehensive review[J]. Computational Social Networks, 2019,6(1):1-23.
- [7] LI F, FENG J, YAN H, et al. Dynamic graph convolutional recurrent network for traffic prediction: Benchmark and solution[J]. ACM Transactions on Knowledge Discovery from Data, 2023,17(1):1-21.
- [8] 周新民,金江涛,鲍娜娜,等.基于注意力卷积长短期记忆模型的城市出租车流量预测[J].中国安全科学学报,2024,34(07):153-162.  
ZHOU Xinmin, JIN Jiangtao, BAO Nana, et al. Urban taxi traffic flow prediction based on attentive ConvLSTM-ResNet model[J]. China Safety Science Journal, 2024, 34(7):153-162.
- [9] GUO S, LIN Y, FENG N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting; proceedings of the Proceedings of the AAAI conference on artificial intelligence, F, 2019 [C].
- [10] ZHAO L, SONG Y, ZHANG C, et al. T-GCN: A temporal graph convolutional network for traffic prediction[J]. IEEE transactions on intelligent transportation systems, 2019,21(9):3848-3858.
- [11] WANG J, JIANG J, JIANG W, et al. Libcity: An open library for traffic prediction; proceedings of the Proceedings of the 29th international conference on advances in geographic information systems, F, 2021 [C].



作者简介:周新民(1977—),男,湖南新邵人,博士,教授,博士生导师,主要从事智慧交通、商务智能与大数据、AI大模型等方面的研究。  
E-mail:zhouxinmin2699@163.com。